

UNIVERSIDAD COMPLUTENSE DE MADRID



Msc. BIG DATA, DATA SCIENCE & BUSINESS ANALYTICS

CLASIFICACIÓN DE ZONAS DE ALTO PELIGRO EN LA CIUDAD DE FILADELFIA

Tutores

Carlos Ortega

Santiago Mota

Daniel Núñez Vargas

1-1768-0617

Septiembre 2025

Resumen

Filadelfia es una de las ciudades más densamente pobladas de Estados Unidos y enfrenta importantes retos de seguridad ciudadana. Comprender la dinámica espacial y temporal del delito es clave para diseñar estrategias preventivas. Este trabajo busca responder a una pregunta central: ¿es posible, a partir de datos retrospectivos, clasificar las zonas en seguras o peligrosas para el día de mañana sin disponer aún de los registros futuros? La relevancia de este enfoque radica en su aplicabilidad práctica para optimizar recursos y reducir los altos niveles de criminalidad existentes.

La investigación se apoya en más de 200,000 registros de crímenes reportados en Filadelfia entre diciembre de 2023 y julio de 2025, enriquecidos con información socioeconómica a nivel de ZCTA (Zip Code Tabulation Area). A partir de esta base se construyó un *risk score* retrospectivo que combina intensidad per cápita, intensidad por área, densidad poblacional y proporción de delitos violentos. Con base en su distribución, se estableció un umbral para clasificar cada zona como segura o peligrosa. Asimismo, se incorporaron variables temporales, contextuales y demográficas, junto con medidas de autocorrelación espacial (I de Moran) para identificar patrones de dependencia entre áreas vecinas.

El análisis geoespacial confirmó una autocorrelación positiva significativa: las zonas con alta criminalidad tienden a concentrarse en el centro y sur de la ciudad. A partir de estos hallazgos, se entrenó un modelo de clasificación con *Random Forest* que integra predictores geográficos y socioeconómicos, logrando capturar tanto la dimensión espacial inmediata como el contexto social de cada área.

Índice

1. Análisis Exploratorio de los Datos (EDA)	3
1.1. Primer vistazo	3
1.2. Coordenadas Faltantes	4
2. Indicador de Riesgo	5
2.1. Variables Temporales	6
2.2. Variables Contextuales	7
2.3. Variables Demográficas	7
2.4. Construcción del Score	8
2.4.1. Tratamiento de outliers	9
3. Análisis Geoespacial	10
3.1. Distribución espacial del Score de Riesgo	10
3.2. Retardo Espacial	11
3.3. Correlación Local	12
4. Modelado	13
4.1. Acercamiento con Machine Learning	14
4.2. Selección de variables y Feature Engineering	14
4.2.1. Risk Score Lag	14
4.2.2. Ingreso Promedio	15
4.2.3. Correlación Local	16
4.2.4. Lontigud y latitud	17
4.3. Random Forest	17
5. Conclusiones	19
5.1. Recomendaciones y Limitaciones	19
Referencias	20
Anexos	21

1. Análisis Exploratorio de los Datos (EDA)

La base de datos primaria que se utilizará en el presente estudio corresponde a todos los crímenes reportados en la ciudad de Filadelfia, Estados Unidos, entre el 31 de diciembre de 2023 y el 7 de julio de 2025, con un total de 243 761 registros. La base se actualiza diariamente, lo que amplía su potencial, pero recalculer el score y reentrenar el modelo tendría un alto costo. Por ello, se plantea la hipótesis de que con los datos históricos disponibles hasta hoy es posible generar indicadores que permitan clasificar las zonas peligrosas en periodos futuros.


Los datos fueron extraídos del repositorio oficial de la ciudad (OpenDataPhilly) y se encuentran en formato de geografía espacial, lo que facilita su análisis geoestadístico. La base contiene 14 variables diferentes; sin embargo, en este documento se describen únicamente aquellas que, a priori, se consideran relevantes para el análisis:

- **the_geom:** Geometría espacial en formato WKT (Well Known Text).
- **dc_dist:** Código del distrito policial (1-25) - división administrativa de la policía de Filadelfia
- **psa:** Área de Servicio Policial (Police Service Area)
- **dispatch_date_time:** Fecha y hora completa cuando se despachó la llamada de emergencia.
- **location_block:** Descripción textual de la cuadra donde ocurrió el incidente.
- **text_general_code:** Descripción textual del tipo de delito según clasificación UCR.
- **lat, lng:** Latitud y longitud en grados decimales (WGS84).

1.1. Primer vistazo

El uso de datos espaciales ofrece la posibilidad de aplicar herramientas especializadas de análisis y visualización. Al proyectar los registros en un mapa, se obtiene la representación mostrada en la Figura 1.

Figura 1: Distribución espacial de incidentes criminales en Filadelfia



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

En ella se aprecia la distribución de incidentes en Filadelfia, junto con dos concentraciones de puntos (en verde) ubicadas fuera del área urbana, lo que sugiere la presencia de valores atípicos o registros erróneos que deberán corregirse. Una ventaja de trabajar con información geográfica es que dichas inconsistencias pueden imputarse utilizando coordenadas de áreas cercanas, preservando la coherencia espacial de la base de datos.

1.2. Coordenadas Faltantes

El primer paso será establecer un procedimiento para tratarlas en los casos en que no se disponga de información. En un análisis preliminar se identificaron 9899 registros sin latitud o longitud, y únicamente 17 observaciones con el bloque vacío, lo que sugiere que la variable *location_block* podrá servir como insumo para la imputación, ya que ambas hacen referencia a ubicaciones geográficas pero de distinta manera.

Este acercamiento consistió en identificar estas observaciones y compararlas con registros que sí contenían coordenadas. Encontramos un patrón recurrente, ejemplificado a continuación:

Bloque	Latitud	Longitud
1900 Block S Christopher Columbus BLV	NaN	NaN
1900 Block S Christopher Columbus BLVD	39.9221	-75.1523

Cuadro 1: Coordenadas geográficas de bloques analizados


Para un mismo bloque existen registros con y sin coordenadas; la única diferencia se encuentra

en una ligera variación textual (“BLV” vs. “BLVD”). Este comportamiento se repite en miles de observaciones, por lo que el primer paso será depurar y normalizar la variable *location_block*, ya que ello permitirá realizar la imputación de coordenadas de manera confiable. Para este proceso se aplicarán técnicas de text mining, tales como la eliminación de caracteres especiales y abreviaturas inconsistentes (ej. BLV $\rightarrow$ BLVD), conversión a minúsculas, uso de diccionarios para el correcto mapeo de caracteres y eliminación de espacios extra para uniformar los textos.

Con esta estrategia, de los 9899 registros que en un inicio tenía sus coordenadas como valores vacíos, se logró reducir ese número a tan solo 960 registros. Imputar el resto de observaciones implicaría un análisis más específico; sin embargo, es más el costo en el que se incurriría que el simple hecho de descartarlas para efectos del trabajo propuesto, ya que solo representan un 0.40 % del número total de registros.

El resultado final de aplicar estos ajustes se puede ver de manera tangible en los siguientes mapas, en donde el de la izquierda muestra todos los puntos exactos en donde se registró un crimen y el de la derecha es un mapa de calor identificando cuáles son esas zonas que tienden a tener mayor actividad delictiva.

Figura 2: Distribución espacial de incidentes criminales en Filadelfia



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

2. Indicador de Riesgo

Elaborar un indicador de riesgo únicamente a partir de estadísticas frecuentistas podría generar un sesgo importante hacia las zonas con mayor población, ya que en ellas, naturalmente, se concentran más incidentes.


La intención es construir un indicador más robusto y granular, incorporando no solo la frecuencia de delitos, sino también dimensiones adicionales como periodo del día, características del área (extensión geográfica y densidad poblacional) y la relación entre los delitos violentos y no violentos. Entre las características principales que tendrá el indicador es que su rango oscilará entre $[0, 1]$, pero también se definirán umbrales de tal modo que se pueda clasificar el riesgo en dos niveles diferentes: Seguro y Peligroso.

Para lograrlo, el primer paso consiste en extraer y transformar la información disponible en la base actual, de manera que se puedan generar métricas que capturen estas relaciones y permitan una evaluación más precisa del riesgo.

2.1. Variables Temporales

La inclusión de estas variables resulta fundamental, ya que la ocurrencia del crimen no puede interpretarse únicamente como un fenómeno espacial: existe un componente temporal relevante que influye en la dinámica delictiva. Ejemplo de esto es la variable *hour*, en donde si se analiza la distribución se distingue que hay un claro patrón sistemático y predecible.

Figura 3: Distribución de la variable *hour*



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

El principal hallazgo es que la mayoría de los crímenes ocurren durante el día, particularmente entre las 10:00 a.m. y las 6:00 p.m., lo cual resulta consistente con el hecho de que en estas horas se concentra la mayor actividad poblacional.

Un punto crítico se observa alrededor de las 4:00 pm, momento en el que una parte importante de la población finaliza su jornada laboral y se incrementa el flujo urbano, generando así un mayor número de potenciales víctimas.

En contraste, durante la noche y la madrugada, si bien estas horas suelen percibirse como peligrosas, la menor afluencia de personas se traduce en una reducción en la cantidad de víctimas potenciales y, por ende, en un menor número de incidentes reportados.

A modo de conclusión, el factor temporal no es alaeatrio y deberá ser considerado en la creación del indicador de riesgo. Por esta razón, partir de la fecha y hora del crimen, se procede a derivar un conjunto de variables que enriquecen el análisis, siendo la principal:

- **Periodo del día:** clasificado en Mañana (6:00–12:00), Tarde (12:00–20:00) y Noche (20:00–6:00).

2.2. Variables Contextuales

Más allá del volumen absoluto de delitos en una zona, resulta relevante analizar la naturaleza de las ofensas. Un área con baja criminalidad total puede, no obstante, presentar un riesgo elevado si una proporción considerable de los incidentes corresponde a delitos violentos.

Para capturar esta dimensión, se analizó la variable *crime_description*, a partir de la cual se estableció una clasificación binaria entre ofensas violentas y no violentas. Para consultar la lista de cuáles crímenes fueron considerados violentos y cuáles no, referirse a los anexos, cuadro 8.

El cuadro resumen final se presenta a continuación, en donde era de esperarse que hubiera una mayor cantidad de ofensas no violentas.

Tipo de delito	Conteo
Violentos	48 472
No Violentos	123 265

Cuadro 2: Conteo por tipo de crimen

2.3. Variables Demográficas

Aunque la base de datos inicial no incluía variables demográficas, su incorporación resulta esencial para evitar sesgos en la estimación del riesgo. Para ello, se consultó el censo oficial de los Estados Unidos con el objetivo de descargar los geometrías de cada unos de los ZCTA. Con esta información se procedió a realizar un cruce espacial que le asigna a cada crimen reportado un código postal (ZCTA) a partir de las coordenadas en la que ocurrió. Esta metodología permite aprovechar la geometría definida de cada área para realizar análisis de correlación local entre zonas. Además, a cada ZCTA se le asociaron variables socioeconómicas provenientes también del censo de Estados Unidos, lo que enriquece la base al vincular cada registro no solo con una zona postal, sino también

con características sociodemográficas relevantes para la construcción del *risk score*. Entre la lista de variables incluidas para cada área postal destacan :

- Población total y Población por etnia
- Ingreso (Promedio, Mediana)
- Cantidad de hogares
- Porcentaje de hogares con ingresos menores a \$25,000 dólares, y porcentaje de hogares con ingresos mayores a los \$150,000 dólares
- Índice de Gini

2.4. Construcción del Score

Un aspecto clave en la construcción del score de riesgo es realizar primero la separación entre los conjuntos de entrenamiento (train) y prueba (test). Esto es fundamental porque, de lo contrario, se estaría utilizando información futura (test) para construir un índice que, en teoría, debe elaborarse únicamente a partir de datos históricos ya conocidos. En otras palabras, se trata de una variable con carácter retrospectivo, y por tanto su cálculo debe basarse solo en la información disponible hasta ese momento.

La granularidad del índice se definirá a nivel de código postal y momento del día. En la práctica, esto significa que para cada código y para cada franja horaria (mañana, tarde y noche) existirá una estimación del nivel de riesgo correspondiente. Esta estructura permite capturar tanto las diferencias espaciales como las variaciones temporales en la incidencia delictiva, lo que facilita su interpretación y aplicación en contextos de negocio y seguridad pública. Dicho esto, el risk score para el área postal i para el momento del día j viene dado por

$$Risk\ Score_{ij} = w_0 \cdot IC_{ij} + w_1 \cdot IA_{ij} + w_2 \cdot D_{ij} + w_3 \cdot V_{ij}$$


Donde,

- IC_{ij} corresponde a la intensidad per cápita para el área i en el momento j
- IA_{ij} corresponde a la intensidad por área para el área i en el momento j
- V_{ij} corresponde a la relación entre crímenes violentos y no violentos para área i en el momento j
- D_{ij} corresponde a la densidad poblacional para área i

Para la construcción de las intensidades se utiliza un enfoque de contracción Poisson-Gamma (Bayes Empírico). Este método permite estimar el riesgo como una tasa per cápita y por área,

aplicando una agrupación parcial hacia la media global. De esta manera, se reduce el sesgo asociado a zonas con poca información y se obtiene una medida más estable y confiable. La distribución del score ya construido se muestra a continuación:

Figura 4: Distribución de la variable *risk score*



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

2.4.1. Tratamiento de outliers

A simple vista, en el gráfico 4, se aprecia una cola derecha inusualmente larga, aunque explicada únicamente por un número reducido de observaciones. Al investigarlas con mayor detalle, se identifica que corresponden a zonas con densidad poblacional extremadamente alta. En particular, los códigos postales 19102, 19103 y 19107 que se localizan en pleno centro de la ciudad.

A pesar de ser Filadelfia la segunda ciudad más densamente poblada de los Estados Unidos, estas observaciones corresponden a outliers sin lugar a dudas, por esta razón, se procede con un tratamiento sobre los mismos. Se procede a analizar cómo están los demás momentos del día para el código postal 19102:


ZCTA	Momento del día	Risk Score
19102	Afternoon	0.883255
19102	Night	0.635147
19102	Morning	0.562597

Cuadro 3: Risk Score para Código Postal (ZCTA) 19102

Como se observa, para una misma localidad los scores pueden variar de manera considerable entre distintos momentos del día. Dado que se trata de un problema de naturaleza espacial, la estrategia de imputación más adecuada es aquella que considere la ubicación geográfica. Por ello, los

valores atípicos fueron reemplazados por la media del risk score correspondiente a los tres posibles momentos del día para esa misma zona. Tras aplicar esta técnica, la distribución resultante de la variable es la siguiente:

Figura 5: Distribución de la variable *risk score* sin outliers



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

La distribución es coherente con lo que esperaríamos tras eliminar outliers. Muestra una concentración clara de valores en el rango medio-bajo y una dispersión más moderada en los valores altos, sin que se contaminen los resultados por observaciones extremas.

Según lo mencionado anteriormente, más allá de calcular el score de riesgo, nuestro objetivo es asignar una etiqueta a aquellas zonas identificadas como altamente peligrosas. En la nueva distribución, destaca claramente la separación que presentan las áreas con un risk score superior a 0.5. Precisamente, estas zonas son las que resultan de mayor interés para el análisis.


Por lo tanto, para efectos de clasificación, se utilizará un umbral de 0.5 para asignar la etiqueta *Bajo* a las zonas con menor riesgo y *Alto* a aquellas con mayor riesgo.

3. Análisis Geoespacial

3.1. Distribución espacial del Score de Riesgo

Con el score de riesgo calculado para cada área de código postal y franja horaria, el siguiente paso consiste en evaluar la existencia de correlaciones espaciales entre el índice de riesgo generado y diversas variables sociodemográficas, tales como el índice de Gini, con el objetivo de identificar patrones de vulnerabilidad social asociados a la peligrosidad geográfica.

Figura 6: Distribución espacial del Risk Score (Izquierda) y el Índice de Gini (Derecha)



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov


Los mapas muestran un patrón espacial consistente: las zonas centrales concentran tanto los valores más altos del risk score como del índice de Gini, mientras que hacia la periferia predominan niveles más bajos en ambas variables. Esta coincidencia sugiere una relación positiva entre desigualdad socioeconómica y riesgo de crimen, lo que indica que los barrios con mayores niveles de desigualdad tienden también a presentar mayor exposición a la violencia y conductas delictivas.

3.2. Retardo Espacial

En series temporales, se conoce como retardo la misma serie analizada pero un tiempo $t - k$ mientras que en el análisis geoespacial se conoce el retardo como la serie analizada pero en las respectivas vecindades de cada ubicación. Analizando el gráfico 6 se distingue a simple vista que hasta cierto punto sí se cuenta con cierto grado de dependencia espacial, dado que las zonas con risk scores más altos también tienen vecindades con scores altos.

Para ello, se procede a computar el retardo de cada área y la utilización de la I de Moran, que cuantifica la autocorrelación espacial.

Figura 7: Retardo Espacial (Izquierda) y Autocorrelación del Risk Score (Derecha)



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Los resultados presentados en la figura revelan una fuerte evidencia de autocorrelación espacial positiva en el score risk desarrollado para la ciudad de Filadelfia, en donde, desde un punto de vista urbano, esto tiene sentido porque los factores de riesgo (socioeconómicos, demográficos, infraestructura) no se distribuyen de manera aleatoria en el espacio.

El mapa del lado izquierdo muestra la distribución espacial del risk score con retardo espacial, donde se observa un claro patrón de clustering, con las zonas de mayor riesgo concentradas principalmente en el área central y sur de la ciudad, mientras que las áreas periféricas tienden a presentar valores más bajos.

Por otro lado, el diagrama de dispersión confirma una relación lineal positiva entre el risk score y su respectivo retardo. Más allá de eso, se confirma que esta relación es estadísticamente significativa con una I de Moran considerada moderada-fuerte y un $p - value$ de 0.001. Esto lo que demuestra es que las zonas con altos valores de riesgo tienden a estar rodeadas por otras zonas de alto riesgo, y de manera viceversa para las zonas de bajo riesgo.


3.3. Correlación Local

La I de Moran calculada previamente refleja la autocorrelación espacial a nivel global, lo que confirma su existencia en el conjunto de áreas postales. Sin embargo, esto no implica que todas ellas presenten el mismo comportamiento. Por ello, resulta necesario complementar el análisis con la I de Moran local, que permite identificar en qué áreas específicas existe dependencia espacial respecto a sus vecinas.

En el panel izquierdo de la Figura 8 se muestran en color marrón las zonas con asociación espacial

significativa, mientras que en azul claro aparecen aquellas sin evidencia estadística relevante. El panel derecho detalla la magnitud y dirección de dicha asociación, distinguiendo clústeres de altos rodeados de altos (HH), bajos rodeados de bajos (LL) y configuraciones mixtas (HL y LH). Las áreas sin significancia se representan en gris.

Figura 8: Significancia por Área Postal (Izquierda) y Magnitud de Asociación (Derecha)



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Los resultados son consistentes con lo mostrado en las Figuras 6 y 7, donde se observa el mismo patrón: una mayor concentración de criminalidad en el centro y sur de la ciudad, con una disminución progresiva hacia la periferia.

4. Modelado

En una primera aproximación se evaluó la posibilidad de desarrollar un modelo geoespacial a nivel de zonas postales (ZCTA) con el objetivo de clasificar cada área en niveles de bajo o alto riesgo. Sin embargo, esta estrategia presentó limitaciones metodológicas importantes. A pesar de contar con más de 100,000 registros individuales de delitos durante 2024, la agregación de los incidentes por ZCTA reducía la unidad de análisis a poco más de 55 observaciones, correspondientes al total de áreas postales presentes en Filadelfia. Esta drástica disminución de la muestra generaba problemas como una elevada probabilidad de sobreajuste y una validación poco confiable.

Dadas estas restricciones, se descartó el enfoque puramente geoespacial a nivel de ZCTA y se optó por una estrategia alternativa basada en modelos de machine learning de clasificación, en la que se aprovecha directamente el volumen completo de observaciones disponibles. Este cambio de enfoque permitió mantener la granularidad original de los datos y garantizar un tamaño muestral adecuado para el ajuste y validación del algoritmo.

4.1. Acercamiento con Machine Learning

Si bien se adoptó un enfoque tradicional basado en modelos de clasificación de machine learning, los insights obtenidos del análisis geoespacial se incorporarán al modelo. Entre estos destacan el score con retardo espacial calculado para cada ZCTA, así como el nivel de asociación de cada área con sus zonas vecinas.

4.2. Selección de variables y Feature Engineering

Un aspecto relevante al incorporar datos socioeconómicos y demográficos es que estos se encuentran agregados por código postal (ZCTA). En consecuencia, todas las variables analizadas desde una perspectiva geoespacial también están disponibles únicamente a nivel ZCTA, lo que genera una limitación: para una base de más de 150,000 registros, solo existen 53 valores numéricos únicos correspondientes a las 53 zonas postales. Para abordar este reto, se aplicó una tramificación mediante Weight of Evidence (WOE) y se evaluó el Information Value (IV), permitiendo al algoritmo seleccionar la segmentación óptima. Solo se detallan aquellas variables que fueron utilizadas en el modelo final.

4.2.1. Risk Score Lag


Como se aprecia en la figura 7, se distingue una relación lineal y positiva entre el risk score de una zona postal con el score de sus vecinos.

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	$(-\infty, 0.32)$	73574	70641	2933	0.039865	1.605431	0.68502
1	$[0.32, 0.40)$	74208	57173	17035	0.229557	-0.365342	0.06962
2	$[0.40, \infty)$	11888	4498	7390	0.621635	-2.072649	0.489408
Totals		159670	132312	27358	0.171341		1.244048

Cuadro 4: Análisis de Binning - Weight of Evidence e Information Value - Risk Score Lag

El análisis de binning evidencia una clara capacidad discriminante de la variable, con un *Information Value* global de 1.244. El primer corte $(-\infty, 0.32)$ agrupa el 46.1 % de los registros con una baja tasa de eventos (3.99 %), mientras que el segundo $[0.32, 0.40)$ concentra el 46.5 % con una tasa moderada (22.96 %). Finalmente, el tercer intervalo $[0.40, \infty)$ representa solo el 7.4 % de los registros, pero con una tasa de eventos muy elevada (62.16 %), confirmando el alto poder predictivo de la variable.

Figura 9: Tramificación óptima de Risk Score Lag



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

En el panel izquierdo se observa la relación lineal negativa obtenida tras aplicar la tramificación mediante WOE, mientras que el panel derecho muestra los rangos de cada intervalo junto con la proporción de eventos correspondiente. En este último se aprecia con claridad que el intervalo mayor a 0.40 concentra una proporción significativamente elevada de eventos clasificados como peligrosos.

4.2.2. Ingreso Promedio

De manera análoga, se tramifica la variable de ingreso promedio por zona postal, siendo los resultados:

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	(-inf, 53 386)	17575	9461	8114	0.461679	-1.422567	0.320192
1	[53 386, 59 668)	22338	14875	7463	0.334094	-0.886429	0.142154
2	[59 668, 61 270.5)	11236	8303	2933	0.261036	-0.535563	0.023808
3	[61 270, 117 040.5)	84748	80640	4108	0.048473	1.400905	0.643451
4	[117 040.5, 153 564)	14812	13354	1458	0.098434	0.638597	0.030419
5	[153 564, inf)	8961	5679	3282	0.366254	-1.027832	0.079188
Totals		159670	132312	27358	0.171341		1.239213

Cuadro 5: Análisis de Binning - Weight of Evidence e Information Value - Mean Income


El análisis de binning para la variable de ingreso promedio (*Mean Income*) muestra patrones claros en la relación con el riesgo, con un *Information Value* de 0.64. Los bins correspondientes a ingresos bajos (0, 53,386) presentan la tasa de eventos más alta (46.17%) y un *WoE* muy negativo (-1.42), indicando fuerte asociación con el riesgo. En contraste, los bins de ingresos medios y altos

(bins 3 y 4, [97, 754, 153, 564]) muestran tasas de eventos bajas (4.85 % y 13.72 %) y *WoE* positivo (1.40 y 0.64), evidenciando un efecto protector y un alto poder predictivo del modelo.

4.2.3. Correlación Local

Del análisis geoespacial, en la figura 8 se extrajo data interesante respecto a la magnitud de la correlación local de cada zona postal y más allá de eso, la dirección de dicha asociación. Esta es una variable de carácter categorico.

Figura 10: V de Cramer (Izquierda) y Distribución por label



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

La *V de Cramer* de 0.46 indica una fuerte asociación con la variable objetivo. Las distribuciones por tipo de correlación local son consistentes con su interpretación: HH (High-High) muestra zonas peligrosas rodeadas de otras zonas peligrosas con valores altos, HL y LH presentan asociaciones moderadas, LL indica zonas seguras rodeadas de áreas seguras con valores bajos, y el label *non-significant* refleja zonas sin correlación local significativa, con distribuciones dispersas y colas largas.

Sin embargo, algunas categorías presentan baja representatividad, lo que podría inducir sobreajuste; por ello, se realizó una recategorización mediante WOE. El resultado de la recategorización fue agrupar todas las categorías excepto la HH, dado a su alto ratio de eventos de casi 40 %.

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	[HL, LH, LL, Non-Significant]	97176	94243	2933	0.030182	1.893697	1.14582
1	[HH]	62494	38069	24425	0.390838	-1.132361	0.685158
Totals		159670	132312	27358	0.171341		1.830978

Cuadro 6: Análisis de Binning - Weight of Evidence e Information Value - Correlación Local

4.2.4. Longitud y latitud

Además, las variables de *Longitud* y *Latitud* son esenciales para identificar zonas de riesgo y serán el input principal del modelo, por lo que se incluirán tras un preprocesado de estandarización.

4.3. Random Forest

El modelo seleccionado como definitivo fue un Random Forest, utilizando las variables previamente descritas. Para su entrenamiento, se emplearon los datos de todos los crímenes ocurridos durante el año 2024, mientras que el conjunto de prueba correspondió a los primeros cinco meses de 2025, resultando en una división aproximada de 73 % para entrenamiento y 27 % para prueba. No se incluyó el mes de junio en el conjunto de prueba, ya que esto habría excedido el 30 % de los datos de test y se decidió mantener un tamaño de entrenamiento suficiente para evaluar la información de manera anual.

El modelo tiene la capacidad de clasificar si una ubicación específica presentará un Alto Riesgo o, por el contrario, no representará un riesgo significativo, es decir, realiza una clasificación binaria. Si bien la curva ROC es una métrica estándar en este tipo de modelos, en este caso no refleja de manera fiel la efectividad del modelo debido a la baja proporción de clientes o zonas en riesgo. Por ello, se priorizaron métricas como precisión y recall, las cuales permiten evaluar de manera más adecuada el desempeño en un contexto donde los eventos de alto riesgo son poco frecuentes.

Métrica	Seguro (0)	Peligroso (1)	Macro Avg	Weighted Avg	Overall
Precision	0.95	0.59	0.77	0.90	
Recall	0.90	0.78	0.84	0.88	
F1-Score	0.92	0.67	0.80	0.88	
Support	49088	9517	58605	58605	
Accuracy					0.88

Cuadro 7: Métricas de Evaluación del Modelo en Test Set


El modelo muestra un rendimiento sólido en el test set, con una precisión general del 88 %, aunque al ser un problema de clasificación altamente desbalanceado no basta con este accuracy general.

El aspecto más relevante debería ser su capacidad para identificar lugares peligrosos, donde se observa un recall de 78 % para la clase "Peligroso", lo que implica que captura aproximadamente 8 de cada 10 zonas de alto riesgo. La precisión para esta clase es de 59 %, aceptable dada la

desproporción de clases (9,517 peligrosos vs 49,088 seguros). Este nivel de precisión indica que aproximadamente 6 de cada 10 predicciones de "lugar peligroso" son correctas, lo cual es razonable para un sistema de alerta temprana donde se puede tolerar cierto nivel de falsos positivos a cambio de una mayor capacidad de detección.

Dado al problema de desbalanceo, conviene más enfocarse en los promedios macro que ofrecen una perspectiva más equilibrada del desempeño en ambas clases, mostrando un modelo robusto que no sacrifica completamente la detección de la clase minoritaria en favor de la mayoría. La importancia de las variables dentro del modelo viene dada por:

Figura 11: Feature Importance



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

El modelo demuestra una sólida capacidad predictiva, sustentada principalmente en variables geoespaciales clave. La latitud y longitud se destacan como las más importantes, seguidas de la correlación local de la zona postal asociada a las coordenadas, lo que confirma que la ubicación geográfica es el factor determinante para identificar lugares peligrosos. Esta jerarquía de importancia resulta coherente desde una perspectiva criminológica, dado que los delitos tienden a concentrarse espacialmente en áreas específicas. Además, el modelo no se limita a coordenadas geográficas, sino que integra de manera efectiva variables socioeconómicas, como el ingreso medio, lo que permite capturar patrones tanto espaciales como contextos socioeconómicos. Esta combinación proporciona un enfoque integral y robusto para la predicción de riesgo, reflejando una comprensión más completa del fenómeno delictivo y ofreciendo información valiosa para la toma de decisiones estratégicas en seguridad pública.

5. Conclusiones

El análisis geoespacial permitió confirmar la existencia de autocorrelación local en la criminalidad de Filadelfia, en donde las zonas con mayor riesgo tienden a estar rodeadas de vecindarios igualmente riesgosos, especialmente en el centro y sur de la ciudad. De manera viceversa, las zonas más seguras tienden a estar rodeadas también por zonas seguras y alejadas del centro. Asimismo, se demostró de manera estadística la relación que existe entre el score y variables socioeconómicas, como por ejemplo el Índice de Gini, en donde se distingue en este caso una relación positiva entre ambas, es decir, las áreas asociadas a un nivel de desigualdad más alto también suelen ser más susceptibles a crímenes.

Todos estos hallazgos se consolidan en un modelo que logra capturar de manera efectiva los patrones espaciales y socioeconómicos previamente identificados. Dicho modelo alcanzó un recall cercano al 80 %, lo que respalda su capacidad para identificar la mayoría de las zonas de alto riesgo. Esto demuestra la viabilidad de utilizar información retrospectiva como base para clasificar áreas con mayor probabilidad de criminalidad en periodos futuros, aun en ausencia de datos prospectivos. De esta manera, se responde de forma afirmativa a la hipótesis inicial planteada en el estudio.

5.1. Recomendaciones y Limitaciones

- El análisis depende de datos históricos, lo que significa que los patrones detectados pueden no capturar cambios abruptos en dinámicas delictivas por lo que se extiende la recomendación de recalcular el score de riesgo y actualizar el modelo con una periodicidad no mayor a tres meses.
- El uso de variables demográficas y socioeconómicas agregadas a nivel de ZCTA introduce pérdida de granularidad. Se recomienda utilizar unidades espaciales aún más pequeñas lo que permitiría capturar la dinámica interna de un área postal y no evaluarla como un todo.
- Las estadísticas sociodemográficas no suelen actualizarse con frecuencia, por lo que se recomienda implementar más variables externas con actualizaciones periódicas más frecuentes.

Referencias

- Dubé, J., y Legros, D. (2014). *Spatial econometrics using microdata*. John Wiley & Sons.
- Neyens, T., Faes, C., y Molenberghs, G. (2012). A generalized poisson-gamma model for spatially overdispersed data. *Spatial and Spatio-temporal Epidemiology*, 3(3), 185-194. Descargado de <https://www.sciencedirect.com/science/article/pii/S1877584511000554> doi: <https://doi.org/10.1016/j.sste.2011.10.004>
- OpenDataPhilly. (2025). *Crime incidents*. Disponible en: <https://opendataphilly.org/datasets/crime-incidents/>. (Último acceso: 14 de septiembre de 2025)
- U.S. Census Bureau. (s.f.-a). *Gini index of income inequality*. U.S. Census Bureau. Descargado de [https://data.census.gov/table/ACSST5Y2021.B19083?q=B19083&g=040XX00US42\\$8600000.860XX00US75852](https://data.census.gov/table/ACSST5Y2021.B19083?q=B19083&g=040XX00US42$8600000.860XX00US75852) (Último acceso: 14 de septiembre de 2025)
- U.S. Census Bureau. (s.f.-b). *Profile of general population and housing characteristics*. U.S. Census Bureau. Descargado de <https://data.census.gov/table/DECENNIALDP2020.DP1?q=2020+Census+ZCTA> (Último acceso: 14 de septiembre de 2025)
- U.S. Census Bureau. (2024). *Zip code tabulation areas (zctas)*. Disponible en: <https://www.census.gov/programs-surveys/geography/guidance/geoareas/zctas.html>. (Último acceso: 15 de septiembre de 2025)
- U.S. Census Bureau, U. D. o. C. (s.f.). *Income in the past 12 months (in 2023 inflation-adjusted dollars)*. U.S. Census Bureau. Descargado de [https://data.census.gov/table/ACSST5Y2023.S1901?q=mean+income&g=040XX00US42\\$8600000](https://data.census.gov/table/ACSST5Y2023.S1901?q=mean+income&g=040XX00US42$8600000) (Último acceso: 14 de septiembre de 2025)

Anexos

Debido a la complejidad que ha supuesto el desarrollo de este análisis, fue necesario separar la lógica en dos scripts diferentes así que para efectos de consultar el código completo se puede seguir el siguiente link:

<https://drive.google.com/drive/folders/1nzevx3f1JEB2Whbe6tDgA8dzWZ29JhIL?usp=sharing>

Cuadro 8: Clasificación de tipos de delitos por categoría

DELITOS VIOLENTOS

Aggravated Assault (Firearm & No Firearm)
Robbery (Firearm & No Firearm)
Homicide (Criminal & Justifiable)
Rape
Other Assaults
Offenses Against Family and Children
Other Sex Offenses (Not Commercialized)
Weapon Violations

DELITOS NO VIOLENTOS


Arson, Thefts, Theft from Vehicle
Motor Vehicle Theft, Burglary (Residential & Non-Residential)
Receiving Stolen Property, Vandalism/Criminal Mischief
Driving Under the Influence, Fraud
Narcotic/Drug Law Violations, Public Drunkenness
Forgery and Counterfeiting, Disorderly Conduct
Embezzlement, Prostitution and Commercialized Vice
Liquor Law Violations, Vagrancy/Loitering
Gambling Violations, All Other Offenses

Distribucion de Risk Level en train y test

Nivel de Riesgo	Test	Train
Low	0.828659	0.837608
High	0.171341	0.162392

Cuadro 9: Distribución de Niveles de Riesgo en Conjuntos de Train y Test


Figura 12: Distribución de variable respuesta en Train y Test



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov


Análisis de variables categóricas

Figura 13: Distribución de variable Hour




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Figura 14: Distribución de variable Momento del día




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Figura 15: Distribución de variable Distrito Policial




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Figura 16: Distribución de variable Área de Servicio Policial




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Figura 17: Distribución de variable por Mes




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Figura 18: Distribución de variable por Temporada del Año




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Figura 19: Distribución de variable por día festivo



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov


Figura 20: Distribución de variable por significancia de correlación local



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

Tramificacion de variables numéricas

Figura 21: Distribución de variable por significancia de correlación local




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	$(-\infty, 0.49)$	77601	71654	5947	0.076636	0.912808	0.295911
1	$[0.49, 0.52)$	34114	28753	5361	0.157150	0.103438	0.002209
2	$[0.52, 0.54)$	27029	16665	10364	0.383440	-1.101181	0.278463
3	$[0.54, \infty)$	20926	15240	5686	0.271719	-0.590237	0.054688
Totals		159670	132312	27358	0.171341		0.631271

Cuadro 10: Análisis de Binning - Weight of Evidence e Information Value - Índice de Gini

Figura 22: Distribución de variable por significancia de correlación local




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	$(-\infty, 20.85)$	49580	40732	8848	0.178459	-0.049331	0.000768
1	$[20.85, 34.05)$	66457	61968	4489	0.067547	1.048834	0.319122
2	$[34.05, 37.70)$	26058	20151	5907	0.226687	-0.349038	0.022204
3	$[37.70, \infty)$	17575	9461	8114	0.461679	-1.422567	0.320192
Totals		159670	132312	27358	0.171341		0.662287

Cuadro 11: Análisis de Binning - Weight of Evidence e Information Value - % de hogares con ingresos inferiores a los \$25 000

Figura 23: Distribución de variable por significancia de correlación local




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	$(-\infty, 5.50)$	42243	26707	15536	0.367777	-1.034388	0.378616
1	$[5.50, 8.55)$	23823	20849	2974	0.124837	0.371244	0.018142
2	$[8.55, 23.95)$	68551	64443	4108	0.059926	1.176691	0.396423
3	$[23.95, \infty)$	25053	20313	4740	0.189199	-0.120930	0.002387
Totals		159670	132312	27358	0.171341		0.795567

Cuadro 12: Análisis de Binning - Weight of Evidence e Information Value - % de hogares con ingresos superiores a los \$150 000

Figura 24: Distribución de variable por significancia de correlación local




Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	$(-\infty, 0.04)$	10351	7598	2753	0.265965	-0.560960	0.024236
1	$[0.04, 0.12)$	35979	27685	8294	0.230523	-0.370795	0.034827
2	$[0.12, 0.39)$	51508	44045	7463	0.144890	0.199101	0.011965
3	$[0.39, 0.55)$	27539	26081	1458	0.052943	1.307988	0.188120
4	$[0.55, \infty)$	34293	26903	7390	0.215496	-0.284044	0.018972
Totals		159670	132312	27358	0.171341		0.278120

Cuadro 13: Análisis de Binning - Weight of Evidence e Information Value - % de Población que se autoidentifica como blanca

Figura 25: Distribución de variable por significancia de correlación local



Fuente: Elaboración propia a partir de datos del Repositorio Oficial de Filadelfia y Data.gov

	Bin	Count	Non-event	Event	Event rate	WoE	IV
0	$(-\infty, 0.27)$	14479	11197	3282	0.226673	-0.348961	0.012332
1	$[0.27, 0.46)$	30470	24904	5566	0.182671	-0.077802	0.001185
2	$[0.46, 0.77)$	43996	36533	7463	0.169629	0.012105	0.000040
3	$[0.77, 0.91)$	35643	32710	2933	0.082288	0.835501	0.116979
4	$[0.91, 0.97)$	23671	20918	2753	0.116303	0.451765	0.025962
5	$[0.97, \infty)$	11411	6050	5361	0.469810	-1.455246	0.218625
Totals		159670	132312	27358	0.171341		0.375122

Cuadro 14: Análisis de Binning - Weight of Evidence e Information Value - % de Población que se autoidentifica como no blanca