

MSC. BIG DATA, DATA SCIENCE & BUSINESS ANALYTICS



Clasificación de zonas de alto peligro en la ciudad de Filadelfia, Estados Unidos

Trabajo Final de Graduación

Daniel Núñez



El diagrama muestra un proceso de cinco pasos para la construcción de un modelo de predicción de delitos. Los pasos están representados por círculos numerados del 1 al 5, conectados por una línea horizontal. Los pasos 2 y 4 tienen un borde rojo, mientras que los otros tienen un borde gris. Las descripciones de los pasos están colocadas alrededor de los círculos, con líneas punteadas que los conectan.

```
graph LR; 1((1)) --- 2((2)); 2 --- 3((3)); 3 --- 4((4)); 4 --- 5((5));
```

DATOS DE CRÍMENES

Se recolectan las estadísticas de los crímenes ocurridos en Filadelfia, USA.

FUENTES EXTERNAS

Se utilizan herramientas espaciales para cruzar los datos criminales con áreas postales y estadísticas socioeconómicas.

CONSTRUCCIÓN DE SCORE

Se construye un índice [0-1] por área postal y franja horaria (Mañana, Tarde, Noche) y con base en esto se asigna un umbral para determinar si una zona es segura o peligrosa.

ANÁLISIS GEOESPACIAL

Análisis de autocorrelación del score de riesgo, así también como la relación que existe con las variables socioeconómicas.



RANDOM FOREST

Construcción de modelo para la clasificación entre zonas seguras y peligrosas utilizando variables espaciales tanto espaciales como socioeconómicas.

ANÁLISIS EXPLORATORIO (EDA)



La base de datos utilizada corresponde a más de 200 000 crímenes reportados en Filadelfia entre diciembre de 2023 y julio de 2025, extraídos de OpenDataPhilly en formato espacial.




Bloque	Latitud	Longitud
1900 Block S Christopher Columbus BLV	NaN	NaN
1900 Block S Christopher Columbus BLVD	39.9221	-75.1523

SCORE DE RIESGO



El objetivo es crear un indicador de seguridad más completo que incluya delitos, horarios, densidad poblacional y geografía, con valores de 0 a 1 para clasificar áreas como "Seguras" o "Peligrosas".





Nivel de Riesgo	Test	Train
Low	0.828659	0.837608
High	0.171341	0.162392

ANÁLISIS GEOESPACIAL





Los resultados muestran una fuerte autocorrelación espacial positiva en el índice de riesgo de Filadelfia, lo cual es lógico ya que los factores de riesgo socioeconómicos y demográficos no se distribuyen aleatoriamente en el territorio.



CORRELACIÓN LOCAL



No todas las áreas tienen el mismo comportamiento, por eso se requiere la I de Moran local para identificar qué zonas específicas muestran dependencia espacial con sus vecinas.





RANDOM FOREST

El modelo fue entrenado con datos de cr menes de 2024 (73%) y probado con los primeros cinco meses de 2025 (27%). Debido a la baja proporci n de zonas de alto riesgo, se priorizaron las m tricas de precisi n y recall sobre la curva ROC para evaluar el desempe o.

M�trica	Seguro (0)	Peligroso (1)	Macro Avg	Weighted Avg	Overall
Precision	0.95	0.59	0.77	0.90	
Recall	0.90	0.78	0.84	0.88	
F1-Score	0.92	0.67	0.80	0.88	
Support	49088	9517	58605	58605	
Accuracy					0.88

Recall: ~ 8 de cada 10 cr menes



Precisi n: ~ 6 de cada 10 cr menes





CONCLUSIONES

- El análisis geoespacial permitió constatar la presencia de autocorrelación local en la criminalidad de Filadelfia.
- Las áreas de mayor riesgo se concentran principalmente en el centro y sur de la ciudad, mientras que las zonas más seguras se localizan en sectores periféricos.
- El modelo desarrollado logró un recall cercano al 80%, demostrando la viabilidad de combinar variables geográficas con socioeconómicas para explicar patrones espaciales.
- Estos resultados confirman que los datos históricos son suficientes para anticipar patrones delictivos en periodos futuros, aun sin contar con información prospectiva, validando así la hipótesis inicial del estudio.

Recomendaciones:

- El análisis basado en datos históricos puede no reflejar cambios repentinos en la criminalidad.
 - El uso de variables a nivel de ZCTA reduce granularidad; se recomienda emplear unidades espaciales más pequeñas.
 - Las estadísticas sociodemográficas se actualizan con poca frecuencia; conviene añadir variables externas más dinámicas.
-



GRACIAS



www.linkedin.com/in/dnunezvargas